

PageRank en Spark

Le projet consiste à implémenter PageRank en Spark RDD et DataFrame à partir des graphes Wikipedia, vous trouverez un graphe par langue différente ici

<https://www.dropbox.com/sh/serapy4ro02phu5/AAASs2Wb2WuwfNoX1FNwwqBDa>

Les graphes sont de différents taille, cela vous permet de tester votre implementation sur des petits et des grands graphes.

Le format des fichiers pour les graphes de Wikipedia est le suivant (une page par ligne):

```
page1 | lien1-1 | lien1-2 | ...  
page2 | lien2-1 | lien2-2 | ...  
...
```

où lien1-1 et lien1-2 sont les deux premiers liens presents sur la page1.

Attention, ce format contient également les liens dits rouges de Wikipedia, c'est à dire des liens vers des pages qui n'existent pas. A vous de ne pas en tenir compte dans votre graphe.

Concernant l'implementation en Spark RDD l'objectif est de produire une version base-line sans aucune optimisation sur le partitioning, et une version optimisée.

Une analyse expérimentale sur des graphes de différentes taille doit comparer les performances des différentes taille.

La date de rendu est le 30 Octobre.